


Interpretable LLM Routing via SAE-Based Contextual Bandits

팀원 : 20231851 이도현

https://github.com/ldh-at/LLM_router.git

문제 제기

- 사람들이 여러 LLM을 쓸 때 어떤 LLM이 답변을 더 잘 해주는지 명확하게 알지 못하고 LLM을 쓴다.
- 기업이나 사용자가 LLM이 좋은 답변을 하는지 평가하기 쉽지 않다.
- 단순 알고리즘으로는 해결할 수 없다.



현재까지의 LLM 평가 방식

Input마다 “어떤 모델이 잘할지” 예측하는 것이 어려움


cost-accuracy tradeoff explicit하게 다루지 못함

=> 애초에 LLM 모델 답변 평가와 의미별 정확도를 따지기 힘들

=> Benchmark를 이용함

Model / Benchmark	GSM8K (May 2021)	HumanEval (Jul 2021)	MBPP (Aug 2021)	MultiPL-E (Aug 2022)	DS-1000 (Nov 2022)	AgentBench (August 2023)	RepoBench (October 2023)	SWE-Bench (October 2023)
GPT-3.5 (Mar 2023)	was evaluated on	was evaluated on	was not evaluated on	was not evaluated on	was not evaluated on	was evaluated before	was evaluated before	was evaluated before
GPT-4 (Mar 2023)	was evaluated on	was evaluated on	was not evaluated on	was not evaluated on	was not evaluated on	was evaluated before	was evaluated before	was evaluated before
StarCoder (May 2023)	was evaluated on	was evaluated on	was evaluated on	was evaluated on	was evaluated on	was evaluated before	was evaluated before	was evaluated before
PaLM 2 (May 2023)	was evaluated on	was evaluated on	was evaluated on	was not evaluated on	was not evaluated on	was evaluated before	was evaluated before	was evaluated before
WizardCoder (Jun 2023)	was not evaluated on	was evaluated on	was evaluated on	was not evaluated on	was evaluated on	was evaluated before	was evaluated before	was evaluated before
Claude 2 (Jul 2023)	was evaluated on	was evaluated on	was not evaluated on	was not evaluated on	was not evaluated on	was evaluated before	was evaluated before	was evaluated before
Llama 2 (July 2023)	was evaluated on	was evaluated on	was evaluated on	was not evaluated on	was not evaluated on	was evaluated before	was evaluated before	was evaluated before
Code Llama (Aug 2023)	was evaluated on	was evaluated on	was evaluated on	was evaluated on	was not evaluated on	was evaluated before	was evaluated before	was evaluated before
Mistral (Sep 2023)	was evaluated on	was evaluated on	was evaluated on	was not evaluated on	was not evaluated on	was not evaluated on	was evaluated before	was evaluated before

LLM routing



*WTP: Willingness to pay.

프롬프트에 대해 가장 좋은 답변을 하는 LLM 으로 보내는 라우터가 필요하다.

프로젝트 주제 및 목표

prompt

'TASK: Solve the following grade school math problem and provide a numerical answer.\n\nThe following are examples of grade scho ...



여러 가지 LLM을 모두
써봐야할까 ?
→ prompt 에 따라 다름

프롬프트의 의미별로 가장 답변을 잘하는 LLM을 골라주는 라우터를
만들자

데이터 셋 - ROUTERBENCH

아래 8개의 **벤치마크의 질문**에 대한 **11개 모델의 프롬프트, 답변, 정답, 비용**을 모아둠

- ① **ARC** — 과학지식과 논리적 추론을 요구하는 고난도 과학·리딩 문제
- ② **HellaSwag** — 상식 기반 시나리오 추론을 평가하는 자연스러운 문장 완성
- ③ **Winogrande** — 자연어 참조 해석과 상식적 판단을 묻는 코어퍼런스 문제
- ④ **MMLU** — 57개 분야의 전문지식 이해도를 평가하는 다도메인 QA
- ⑤ **GSM8K / MATH** — 단계적 계산과 체계적 수학 추론 능력을 측정
- ⑥ **TruthfulQA** — 환각을 유도하는 질문에 대한 사실성·정확성 평가
- ⑦ **BBH** — 일반 LLM이 취약한 고난도 논리·추론 태스크 모음
- ⑧ **HumanEval / BoolQ** — 코드 생성 정확도 및 문맥 기반 QA 능력 평가

데이터 셋 - ROUTERBENCH


아래 8개의 **벤치마크의 질문**에 대한 11개 모델의 **프롬프트, 답변, 정답, 비용**을

Prompt	Answer	Correctness	Cost
'TASK: Solve the following grade school math problem and provide a numerical answer.\n\nThe following are examples of grade scho ...	Answer: To solve this problem... answer is "20"	완전한 정답 [1.0] 불완전한 설명 [0.75] 틀림 [0.0]	0.00035\$

8:1:1로 train/ val/ test로 사용했다.

강화학습 구조 - STATE

연구에서 가장 핵심이 되고 고민을 많이한 부분으로 STATE는 SAE를 이용해 프롬프트를 semantic 으로 분리한 embedding이다.




- 고등 수학 추론에 관한 것
- 과학에서 물리에 관한 것
- 논리적 추론에서 연역법
- 언어적 추론에서 중국어
- 수학에서 덧셈에 관한 것

Sparse AutoEncoder

임베딩 공간을 오히려 늘려서 각 노드를 Sparse하게 semantic 별로 분류한다.

실제 연구에선 SBERT를 이후 4096개의 node로 늘린 후 Sparse한 공간에서 TOPK로 잘라서 임베딩해서 각각 태그를 붙여 의미를 나타냈다. L1

Regularization을 이용함



고등학교 수학 문제를 풀게 했을때 실제 node별 중요도와 태그

'TASK: Solve the following grade school math problem and provide a numerical answer.\n\nThe following are examples of grade scho ...

TOPK STATE

- feature 956 : 0.2955 | grade-school-math
- feature 2337: 0.2632 | grade-school-math
- feature 3600: 0.2549 | grade-school-math
- feature 1283: 0.2498 | grade-school-math
- feature 1711: 0.1932 | grade-school-math


=> 현재 **semantic state**, 고등학교 수학에 강한 모델로 보내게 학습하면

강화학습 구조 - ACTION - contextual bandit

Multi-Armed Bandit의 확장 버전으로 **context에 따라 action**을 선택한다.

Action은 **어떤 LLM으로 보낼 지** 고르는 과정이다.

What is Contextual Bandits




강화학습 구조 - REWARD

Reward는 **Correctness**로 0~1.0사이에서 상위 모델이 답변에 매긴 점수를 바탕으로 채점되었다.

$$\text{Loss} = \text{MSE}(Q, \text{reward matrix})$$

전체 구조

Interpretable LLM Routing via SAE-Based Contextual Bandits



Q network가 semantic 단위 state로 더 잘하는 라우터를 골라줌

하이퍼 파라미터 구성

항목	값
k_top	32 / 64
learning rate	1e-3
batch size	128
epochs	5
λ_{cost}	0 (완전 비활성화)
reward weight	1.0 / 1.5
optimizer	Adam

Semantic에 집중하고 STATE가 중요한 만큼 **SAE embedding**을 32 64로 나눠서 정확도를 비교해 보았다.

하이퍼 파라미터 구성

항목	값
k_top	32 / 64
learning rate	1e-3
batch size	128
epochs	5
λ_{cost}	0 (완전 비활성화)
reward weight	1.0 / 1.5
optimizer	Adam

cost 반영은 단순 API 호출 비용 데이터만 있어서 **latency, memory**등을 실제로 비교하는것을 **future work**로 남겨두겠다.

하이퍼 파라미터 구성

항목	값
k_top	32 / 64
learning rate	1e-3
batch size	128
epochs	5
λ_{cost}	0 (완전 비활성화)
reward 구성	1.0 / 1.5
optimizer	Adam


최대한 정확도를 잃지 않기 위해 reward weight도 올려보았다.

실험 결과

Config	w_corr	k_top	Avg Reward (Router)	Router Top-1	Router Top-3	Router Top-5
0	1	32	0.8222	0.8223	0.8908	0.9118
1	1	64	0.8223	0.8223	0.8918	0.9106
2	1.5	32	1.232	0.8213	0.8929	0.9134
3	1.5	64	1.2328	0.821	0.892	0.9135
BEST	1.5	64	1.2328	0.822	0.8928	0.9157

semantic state가 늘어나면 top 1 3 5 정확도가 모두 높아지는 것을 볼 수 있다.

실험 결과




놀랍게도 **cost** 가중치를 넣지 않았지만 **state**를 64로 늘린 **config 1,301**

cost까지

빠게 나오는 것을 알 수 있다

실험 결과



추가 논의가 필요하지만 **semantic**을 이해하면 알아서 **cost-aware**한 적절한 모델로 보내준다고도 말할 수 있다.

놀랍게도 **cost** 가중치를 넣지 않았지만 **state**를 64로 늘린 **config 1,30**이 **cost**까지

빠르게 나오는 것을 알 수 있다

EX) 고등수학 문제에 대한 top3 - router의 대답 비교 (번역)

prompt

[TASK: 다음의 초등 산수 문제를 풀고 숫자로 된 답을 제시하시오.

다음은 초등 산수 문제와 그 답의 예시입니다:

Question: 숲에 나무가 15그루 있습니다. 오늘 일꾼들이 나무를 심습니다. 다 심고 난 뒤에는 21그루가 됩니다. 일꾼들은 몇 그루를 심었나요?

Answer: 6

Question: 주차장에 차가 3대 있습니다. 여기에 2대가 더 도착했습니다. 총 몇 대가 되었나요?

Answer: 5

Question: Leah는 초콜릿이 32개, 그녀의 여동생은 42개를 가지고 있었습니다. 둘이서 35개를 먹었다면, 남은 총 초콜릿은 몇 개인가요?

Answer: 39

Question: Jason은 사탕 20개를 가지고 있었습니다. 그는 Denny에게 몇 개를 주었습니다. 지금 Jason에게는 12개가 남아 있습니다. Jason은 몇 개를 주었나요?

Answer: 8

Question: Shawn은 장난감이 5개 있습니다. 크리스마스 선물로 엄마와 아빠에게서 각각 2개씩 받았습니다. Shawn은 총 몇 개가 되었나요?

Answer: 9

"6명의 아이는 완두콩을 좋아하고, 9명은 당근을 좋아하고, 5명은 옥수수를 좋아합니다. 옥수수를 좋아하는 아이들의 비율(%)은 얼마인가요?"

gpt-4-1106-preview —
Q=1.0229

claude-v2 —
Q=1.0181

claude-v1 —
Q=0.9956

EX) 고등수학 문제에 대한 top3 - router의 대답 비교

TOP 1

논리적 설명이 담겨있고 문제 해설 매우 자세함

"옥수수를 좋아하는 아이들의 비율을 구하려면 먼저 Carolyn의 보육원에 있는 아이들의 총수를 알아야 합니다.

이를 위해 각 야채를 좋아하는 아이들의 수를 더해줍니다:

완두콩을 좋아하는 아이 수: 6

당근을 좋아하는 아이 수: 9

옥수수를 좋아하는 아이 수: 5

총 아이 수 = 6(완두콩) + 9(당근) + 5(옥수수) = 20명

이제 옥수수를 좋아하는 아이들이 차지하는 비율을 계산합니다:

$(\text{옥수수를 좋아하는 아이 수} / \text{전체 아이 수}) \times 100\%$

$(5 / 20) \times 100\% = 0.25 \times 100\% = 25\%$

따라서, 25%의 아이들이 옥수수를 좋아합니다."

gpt-4-1106-preview —
Q=1.0229

claude-v2 —
Q=1.0181

claude-v1 —
Q=0.9956

EX) 고등수학 문제에 대한 top3 - router의 대답 비교

TOP 2

설명의 연결이 부족하지만 풀이 과정은 맞음

**완두콩을 좋아하는 아이: 6명

**당근을 좋아하는 아이: 9명

**옥수수를 좋아하는 아이: 5명

**총 아이 수를 구하기 위해:

완두콩: 6

당근: 9

옥수수: 5

총합 = $6 + 9 + 5 = 20$

**옥수수를 좋아하는 아이의 비율을 구하기 위해:

**옥수수를 좋아하는 아이 수: 5

전체 아이 수: 20

비율 = $(\text{부분}/\text{전체}) \times 100$

옥수수를 좋아하는 아이 비율 = $(5/20) \times 100 = 25\%$

따라서, 옥수수를 좋아하는 아이들의 비율은 25%입니다.

gpt-4-1106-preview —
Q=1.0229

claude-v2 —
Q=1.0181

claude-v1 —
Q=0.9956

EX) 고등수학 문제에 대한 top3 - router의 대답 비교

TOP 3

근거도 부족하고 해설력도 부족함 수식만 맞음

완두콩을 좋아하는 아이: 6명

당근을 좋아하는 아이: 9명

옥수수를 좋아하는 아이: 5명

총 아이 수는 $6 + 9 + 5 = 20$ 명

옥수수를 좋아하는 아이들의 비율은 $(5 / 20) \times 100 = 25\%$

gpt-4-1106-preview —
Q=1.0229

claude-v2 —
Q=1.0181

claude-v1 —
Q=0.9956

EX) 고등수학 문제에 대한 top3 - router의 대답 비교

TOP 3

근거도 부족하고 해설력도 부족함 수식만 맞음

완두콩을 좋아하는 아이: 6명

당근을 좋아하는 아이: 4명

옥수수를 좋아하는 아이: 5명

이렇듯 의미적 구분을 중심으로 routing이 된 것을 알 수 있음

옥수수를 좋아하는 아이들의 비율은 $(5 / 20) \times 100 = 25\%$

gpt-4-1106-preview —
Q=1.0229

claude-v2 —
Q=1.0181

claude-v1 —
Q=0.9956

EX) 고등수학 문제에 대한 SAE feature(STATE) 비교

Top SAE Features (k_show=20):

feature 956 : 0.2955 | grade-school-math (0.64, n=9290)
feature 2337: 0.2632 | grade-school-math (0.82, n=7234)
feature 3600: 0.2549 | grade-school-math (0.65, n=9134)
feature 1283: 0.2498 | grade-school-math (0.73, n=8182)
feature 1711: 0.1932 | grade-school-math (0.87, n=6821)
feature 3381: 0.1768 | grade-school-math (0.91, n=6559)
feature 3016: 0.1539 | grade-school-math (0.96, n=6187)
feature 2443: 0.1533 | grade-school-math (0.90, n=6658)
feature 2641: 0.1468 | grade-school-math (0.99, n=6011)
feature 3386: 0.1452 | grade-school-math (0.89, n=6676)
feature 368 : 0.1311 | grade-school-math (0.90, n=6608)
feature 1450: 0.1307 | grade-school-math (0.95, n=6267)
feature 2849: 0.1254 | grade-school-math (0.95, n=6248)
feature 3814: 0.1182 | grade-school-math (0.95, n=6299)
feature 1495: 0.1135 | grade-school-math (1.00, n=5961)
feature 831 : 0.1103 | grade-school-math (0.95, n=6255)
feature 2566: 0.1074 | grade-school-math (0.95, n=6297)
feature 423 : 0.0910 | grade-school-math (1.00, n=5960)
feature 122 : 0.0837 | grade-school-math (1.00, n=5968)
feature 816 : 0.0807 | grade-school-math (1.00, n=5960)

hellaswag — 일상 상황 서술의 다음 문장 상식 추론

grade-school-math — GSM8K류 초중등 단계 서술형 수학 문제 풀이

arc-challenge — ARC Challenge 난이도, 초중등 과학/상식 객관식 추론

winogrande — 대명사/상황 기반 상식 코리퍼런스 판별

bias_detection — 응답의 편향/차별 표현 탐지

abstract2title — 논문 초록을 보고 적절한 제목 생성

consensus_summary — 다중 응답 요약/합의 요약

mbpp — 간단한 파이썬 프로그래밍 문제(입출력 예시 기반 코드 작성)

chinese_zodiac — 띠/간지 관련 중국어 상식 질의

Chinese_character_riddles — 한자 수수께끼 풀이

chinese_tang_poetries — 당시(唐詩) 관련 질의/이해

chinese_shi_jing — 시경 관련 질의/이해

accounting_audit — 회계 감사 관련 질의

chinese_ancient_poetry — 고대 중국 시문 해석/완성

chinese_hard_translations — 난이도 높은 중국어 번역

.
. .
.

위와 같이 86개 정도의 의미 구분 feature가 있음. 여기서는


고등수학이란 state가 전부 grade school math 일것을 볼 수 있음

이렇듯 state를 가지고 라우팅을 하면 semantic aware routing을 할 수 있고, 적절한 모델로 보내면 cost-aware routing도 된다는 것을 알 수 있다.

추가 논의 사항 및 보완할 점

단순히 bandit이 아니라 멀티라우팅이 좋은 것 아닌가?

multi- rounding router를 연구한 논문 결과를 보면 대부분의 질문은 한번의 routing으로 처리 가능하고, 많아도 2-hop이면 끝난다.



(a) LLM API Call Count

=> 올바른 라우팅으로 1-hop에 끝낼 수 있음

Reference: Router-R1 (Jiang et al., 2024)

보완할 점

- 연구에서 모델 11개를 직접 돌릴 수 없는 환경적 한계로 실제 routing이 아닌 routerbench라는 데이터셋에 의존해서 실험했다. 또한 데이터 셋에 gpt 4 와 비교할 만한 큰 모델이 없었다는 것이다.
- 정확도가 100이 아닌 것을 보면 multi - rounding이 몇가지 case에서는 필요하다는 것을 알 수 있다.
- 최근 나오는 멀티모달 모델들의 평가는 어떻게 할 지 고민해봐야 할 것 같다.